

Bioinformatika praktikumu

UNEC materiallarından mənbəli konspektlər, işlək layihələr və özünü yoxlama tapşırıqları.

8 dərs · 3 laboratoriya · 24 tapşırıq

16 sentyabr 2026 | Şəxsi tədris nəşri

Bu bələdçi təqdim edilmiş dərslərdən seçilmiş hissələr əsasında repo üçün yenidən hazırlanıb. UNEC-in rəsmi dərsliyi və ya klinik istifadə təlimatı deyil.

Repo: <https://github.com/ali-novruz/bioinformatics-lab>

Mənbələr: [resources/unec/catalog.csv](#); kitablar: [resources/books/pdf-manifest.json](#). Elektron repo bütün kodu, nəticələri və tam mənbə linklərini saxlayır.

1. Məlumat, dəyişən və mənşə

Məqsəd: cədvəldəki rəqəmin hansı bioloji obyektə aid olduğunu izah etmək. Məlumatın formatı onun mənası ilə eyni deyil. `sample_id` rəqəmlə yazılsa belə, hesablama üçün miqdar deyil; nümunənin adıdır. `condition` kateqoriya, `count` qeyri-mənfi tam ölçmə, normalizasiya edilmiş ifadə isə davamlı dəyişən ola bilər. Çatışmayan ölçmə sıfır ifadə demək deyil.

UNEC məlumat və informasiya dərindəki kəmiyyət/keyfiyyət ayrımını RNA-seq cədvəlinə tətbiq edək. Bir sətir gen, sütunlar nümunələrdir. Metadata cədvəli hər nümunənin müalicə qrupunu və bioloji təkrarını saxlayır. İki cədvəlin əlaqəsi sütun sırası ilə deyil, `sample_id` ilə qurulmalıdır. Sütunların yeri dəyişdikdə düzgün uyğunlaşdırma nəticəni dəyişdirməz; mövqeyə görə birləşdirmə isə qrupları səhv verə bilər.

Mənşə qeydi faylın haradan gəldiyini, nə vaxt alındığını, hansı versiyaya aid olduğunu və dəyişdirilib-dəyişdirilmədiyini saxlayır. SHA-256 eyni baytların istifadə edildiyini yoxlayır. O, elmi doğruluğu, müəllifliyi və istifadə hüququnu sübut etmir. Buna görə hash ilə yanaşı accession, mənbə URL-i, müəllif və lisenziya statusu da yazılır.

Praktika: `results/raw-examples/rna-model/counts.tsv` və `metadata.csv` fayllarında nümunə adlarını müqayisə edin. 6 nümunə və 124 gen gözlənilir. Bunlar chr1 üzrə kiçik subsample nəticələridir; bütün yeast genomunu təmsil edən tam eksperiment kimi şərh edilməməlidir.

Keçid meyarı: bir nümunənin mənbədən yekun hesabatə yolunu izah edin; missing, zero və duplicate arasındakı fərqi nümunə ilə göstərin.

Mənbə: U4072, abzas 19-26; U4084, abzas 16-48. Fayl kimlikləri kataloqda saxlanılıb.

2. Bioloji verilənlər bazası

Məqsəd: məlumat bütövlüyünü proqramın yaddaşından asılı olmayan qaydalarla qorumaq. Verilənlər bazası sadəcə böyük Excel cədvəli deyil: cədvəllər arasındakı əlaqələr və qəbul edilən qiymətlər də modelin hissəsidir.

Bu laboratoriyada [sample](#) nümunələri, [gene](#) genləri, [gene_count](#) isə nümunə-gen ölçmələrini saxlayır. [gene_count](#) cədvəlinin əsas açarı iki sütundan ibarətdir: ([sample_id](#), [gene_id](#)). Eyni gen müxtəlif nümunələrdə ölçülə bilər, eyni nümunədə müxtəlif genlər ola bilər; eyni cüt ikinci dəfə əlavə edilə bilməz. Xarici açar mövcud olmayan nümunəyə ölçmə yazılmasını rədd edir. SQLite-da bunun üçün bağlantıda [PRAGMA foreign_keys=ON](#) aktiv edilməlidir.

Sayım mənfəi və ya kəsir ola bilməz. Kod həm qeyri-mənfilik, həm də SQLite daxilində tam ədəd tipini yoxlayır. Bu qayda TPM kimi davamlı qiymətlər üçün uyğun deyil; TPM ayrıca ölçmə tipi və ayrıca sxem tələb edir. Cədvəldə ölçmə vahidini dəyişib əvvəlki sütun adını saxlamaq təhlükəli qarışıqlıq yaradır.

```
SELECT s.sample_id, s.condition, SUM(c.count) AS assigned_fragments
FROM sample s JOIN gene_count c USING(sample_id)
GROUP BY s.sample_id, s.condition
ORDER BY s.sample_id;
```

Bu sorğu hər nümunəyə genlər üzrə təyin edilmiş fragmentləri cəmləyir. Cəm FASTQ-dakı bütün read-lərin sayı deyil: mapping və assignment zamanı fərqli filtrlər tətbiq edilib. [run_study_database.py](#) SQL cəmlərini ilkin matrisin ümumi cəmi ilə tutuşdurur.

Keçid meyarı: 744 qeyd, 6 nümunə, 124 gen alınmalıdır; integrity check [ok](#), foreign-key pozuntuları boş olmalıdır. Bir keyfiyyət qaydasının pozulmasını testlə göstərin.

Mənbə: U4084, abzas 16-69; U4129 metadata ilə mövzunun yoxlanması nümunəsidir: faylın daxilində genetika deyil, database sualları var.

3. Data mining və sızmasız maşın öyrənməsi

Məqsəd: çoxsaylı xüsusiyyətlərdən model qurarkən test məlumatının qərarlara qarışmasının qarşısını almaq. Khan mikroarray nümunəsində 2308 xüsusiyyət, cəmi 63 training nümunəsi var. Xüsusiyyətlərin çoxluğu güclü proqnoza zəmanət vermir; təsadüfi əlaqələri tapmağı asanlaşdırır.

Ardıcılıq belədir: sıfır dispersiyalı sütunları çıxar, ANOVA ilə xüsusiyyət seç, standartlaşdır, linear SVM öyrət. Bu addımların hamısı bir pipeline daxilindədir. Beşqat cross-validation zamanı hər training fold öz xüsusiyyətlərini və orta/standart sapmalarını öyrənir. Bütün 83 nümunədə əvvəlcədən gen seçib sonra cross-validation etmək test məlumatını təlimə sızdırardı.

Grid search yalnız 63 training nümunəsində $k = 25, 100, 500$ və $C = 0.01, 0.1, 1$ seçimlərini müqayisə edir. Balanced accuracy hər sinif üzrə recall-un ortasıdır; çoxluq sinfi nəticəni təkbəşinə idarə etmir. Ən çox rast gəlinən sinfi deyən dummy model nə qədər irəliləyiş olduğunu görmək üçün başlanğıc müqayisədir.

Saxlanmış icrada 25 xüsusiyyət və $C=0.01$ seçildi. Seçim üçün istifadə olunan CV balı 1.0-dır, lakin bu, qərəzsiz son generalizasiya qiyməti deyil. Bir dəfə qiymətləndirilən 20 test nümunəsindən 19-u düzgün təsnif edildi. Test nəticəsinə baxıb grid-i yenidən uyğunlaşdırmaq həmin dəsti inkişaf dəstinə çevirər; yeni qiymətləndirmə üçün yeni məlumat lazım olar.

V1 kimi sütun adları təsdiqlənmiş gen simvolları deyil. Ən yüksək bal alan sütunu biomarker adlandırmaq üçün probe annotasiyası, müstəqil cohort və bioloji yoxlama lazımdır. Mənbənin əvvəlcədən etdiyi preprocessing-in müstəqilliyi burada müəyyən edilməyib.

Keçid meyarı: preprocessing-in niyə fold daxilində olması lazım olduğunu izah edin; accuracy və balanced accuracy-ni confusion matrix-dən hesablayın.

Mənbə: U4096, abzas 17-38 və 85-93; U4114, abzas 75-84; U4117, PDF səhifə 41, 55-56; U4252, slayd 4-7.

4. Genotipdən fenotipə

Məqsəd: variant, allel, genotip və fenotipi ayrı anlayışlar kimi istifadə etmək. Allel müəyyən genomik mövqedəki alternativ ardıcılıq variantıdır. Diploid autosomal lokusda fərd adətən valideynlərdən bir nüsxə alır; eyni və fərqli allellər homozigot və heterozigot vəziyyət yarada bilər. Haploid genom və cinsiyyət xromosomları üçün ploidiyanı ayrıca nəzərə almaq lazımdır.

VCF-də **0/1** genotipi REF və birinci ALT allelinin mövcudluğunu göstərir. **0|1** phased qeyddir; **0/1** isə bu faza məlumatını vermir. REF alleli sağlam, ALT alleli xəstəlik alleli demək deyil. Referens genom müqayisə çərçivəsidir, klinik normalın universal təsviri deyil.

Fenotip müşahidə olunan xüsusiyyətdir. Genotip, mühit, inkişaf mərhələsi və onların qarşılıqlı təsiri fenotipə töhfə verə bilər. Poligen xüsusiyyətdə bir neçə gen bir əlamətə təsir edir. Pleiotropiyada isə bir gen bir neçə xüsusiyyətlə bağlıdır. Bunlar bir-birini əvəz edən terminlər deyil. Hipomorf allel funksiyası azalmış alleldir; genotip və mühit arasındakı ümumi uyğunsuzluğun adı deyil.

İrsiyyət müzakirəsində ayrıca mexanizmləri ayırın: nüvə genomu, mitoxondrial genom və epigenetik vəziyyət eyni ötürülmə qaydasına malik deyil. Sperm hüceyrələrində mitoxondri var; insanlarda mitoxondrial irsiyyətin əsasən maternal olması onların spermada olmaması ilə izah edilmir.

Praktika: mövcud variant layihəsində bir VCF sətirinin CHROM, POS, REF, ALT, FILTER və GT sahələrini izah edin. **PASS** yalnız tətbiq edilmiş texniki filtrlərin keçildiyini bildirir. Patogenlik, penetrantlıq və səbəb-nəticə üçün başqa sübutlar tələb edilir.

Keçid meyarı: eyni variantın iki fərqli genom build-də koordinatlarının niyə eyni olmaya biləcəyini və ploidiyanın genotipə təsirini izah edin.

Mənbə: U4126, abzas 17-31 və 50-54; U4139, abzas 17-22. Dəqiqləşdirmələr üçün errata.

5. Sequence bazaları və BLAST

Məqsəd: axtarış aləti, axtarılan kolleksiya və nəticə qeydini ayırmaq. GenBank ardıcillıq qeydləri saxlayan resursdur; BLAST oxşarlıq axtarışı üçün proqramlar ailəsidir. BLASTN və BLASTX ayrıca verilənlər bazası deyil. Eyni proqram müxtəlif database-lərə qarşı işlədilə bilər.

BLASTN nukleotid sorğunu nukleotid kolleksiyası ilə müqayisə edir. BLASTP protein-protein axtarışdır. BLASTX nukleotid sorğunu altı oxuma çərçivəsində tərcümə edib protein kolleksiyası ilə müqayisə edir. TBLASTN isə protein sorğunu tərcümə olunan nukleotid kolleksiyasında axtarır. Yanlış proqram seçimi bioloji sualı dəyişdirə və uyğun nəticələri qaçıra bilər.

Nəticədə percent identity, alignment length, query coverage, score və E-value birlikdə qiymətləndirilir. Yüksək identity çox qısa uyğunlaşmadan gələ bilər. E-value müəyyən axtarış şərtlərində təsadüfən gözlənilən ən azı bu qədər güclü uyğunlaşmaların sayını ifadə edir; database ölçüsündən də asılıdır. Rəngli score zolağı nukleotid uzunluğu ölçüsü deyil. Oxşarlıq təkbəşinə eyni funksiya və ya birbaşa ortologiya sübut etmir.

Praktika: lokal alignment layihəsində iki qısa sequence üçün score və alignment length-i ayrı yazın. Sonra gələcək BLAST icrası üçün proqram versiyası, database adı/tarixi, sorğu accession-u və parametrlərdən ibarət qeyd hazırlayın. Bu dərsin əlavə olunması ayrıca BLAST axtarışının icra edildiyi mənasına gəlmir.

PubMed bibliografik axtarış resursudur. Qeydin pulsuz görünməsi bütün məqalələrin tam mətninin pulsuz olduğu mənasına gəlmir. Tam mətn linki və istifadə şərti ayrıca yoxlanmalıdır.

Keçid meyarı: nukleotid sorğusu ilə uzaq protein homalogiyası araşdırması üçün BLASTX seçiminin səbəbini izah edin; qısa uyğunlaşmanın yüksək identity-sini tənqidi şərh edin.

Mənbə: U4208, slayd 3-15; [NCBI BLAST sənədləri](#).

6. Hipotez, qeyri-müəyyənlik və FDR

Məqsəd: müşahidə olunan fərqi statistik və bioloji mənada ayrı qiymətləndirmək. H_0 əvvəlcədən sübut edilmiş fikir deyil; model altında sınaqdan keçirilən null hipotezdir. Onu rədd edə bilməmək doğruluğunu sübut etmir. İki orta qiymətin 20 və 50 olması nümunə sayı, variasiya və dizayn bilinmədən test qərarı verməyə kifayət etmir.

P-value H_0 və testin digər fərziyyələri doğru olduqda müşahidə edilən qədər və ya daha ekstremal test statistikasının ehtimalıdır. Bu, H_0 -ın doğru olması ehtimalı və ya nəticənin səhv olma ehtimalı deyil. $p < 0.05$ bioloji əhəmiyyət və ya klinik fayda sübut etmir. Effektin ölçüsü, interval, data keyfiyyəti və əvvəlcədən seçilmiş analiz planı birlikdə təqdim edilir.

Min həqiqi null hipotezi ayrı-ayrı 0.05 həddində yoxladıqda, kalibrə edilmiş testlər üçün gözlənilən yanlış müsbətlərin sayı 50-dir. Bu, hər icrada dəqiq 50 alınacaq demək deyil. Bizim seed-i sabit Welch t-test simulyasiyamızda 47 nəticə həddi keçdi. Benjamini-Hochberg düzəlişindən sonra bu realizasiyada sıfır nəticə qaldı. Bu bir sınaq BH-nin bütün mümkün datada sıfır səhv verəcəyini göstərmir.

BH uyğun fərziyyələr altında rədd edilən hipotezlər arasında yanlış kəşflərin payının gözlənilən qiymətini idarə edir. FDR və ailə üzrə ən azı bir yanlış müsbət ehtimalı eyni ölçü deyil. Hipotezlər arasındakı asılılıq strukturu metodun şərtlərinə təsir edə bilər.

Real RNA nümunələrinin library totals xülasəsi ayrıca hesablanır. Library ölçülərinin yaxınlığı batch təsirinin yoxluğunu və ya bütün genlərin ifadəsinin eyniliyini sübut etmir. Bu xülasə QC məlumatıdır, differential expression testini əvəz etmir.

Keçid meyarı: simulyasiya və bioloji müşahidəni ayırın; H_0 -ı rədd etməmək üçün düzgün cümlə qurun; p-value, FDR və effekt ölçüsünün üç fərqli sualını yazın.

Mənbə: U4226, abzas 37-55; U4236, abzas 12 və 23-28; U4230, ehtimal, etibar intervalları və hipotez yoxlaması bölmələri; Think Stats, fəsil 9.

7. Proqram təminatı və təkrarlana bilən icra

Məqsəd: nəticəni yalnız bir şəxsin kompüterində işləyən əməliyyatlardan ayırmaq. U4178-də MATLAB matrisləri və proqram faylları təqdim olunur. Repo Python istifadə edir, lakin əsas dərs dəyişmir: giriş, əməliyyat və çıxış aydın olmalıdır. Köhnə MATLAB slaydları cari toolbox imkanlarının yoxlanmış siyahısı kimi təqdim edilmir.

MATLAB-da indekslər adətən 1-dən, Python-da 0-dan başlayır. NumPy-da $a * b$ elementlər üzrə vurmadır, $a @ b$ matris vurmaşdır. Ölçülər uyğun olsa belə, yanlış operator bioloji mənanı dəyişə bilər. Gen-nümunə matrisini nümunə-gen matrisinə çevirmək sadəcə texniki detal deyil: modelin hansı oxu müşahidə saydığı aydın yazılmalıdır.

Hər yeni icra ayrıca qovluğa yazılır. `run.json` girişlərin SHA-256 izlərini, parametrləri, mühit məlumatlarını və mənbə kodunun izlərini saxlayır. Seed təsadüfi seçimləri sabitləşdirir; paket versiyaları, hesablama arxitekturası və paralel əməliyyatlar da nəticəyə təsir edə bilər. Buna görə seed təkbaşına tam reproduksiya təmin etmir.

Saxlanmış nəticəni yoxlamaq iki səviyyəlidir: faylların hash uyğunluğu nəticənin dəyişmədiyini göstərir; kodu təkrar işlətmək isə hazırkı mühitin nəticəni yenidən yarada bildiyini yoxlayır. Bunlar ayrı sübutlardır. Tarixi nəticənin commit-i əvvəlki ola bilər; dirty flag və həmin anda saxlanmış kod hash-ləri gizlədilmir.

Praktika: yeni laboratoriyalardan birini iki dəfə işlədin. Yeni run qovluqları yaranmalıdır. Elmi xülasələri müqayisə edin; vaxt nişanlarının fərqli olması gözləniləndir. Mövcud snapshot-u səssizcə əvəz etmək əvəzinə yeni nəticənin mənşəyini saxlayın.

Keçid meyarı: “fayl eynidir”, “kod eynidir” və “nəticə təkrar alındı” ifadələrinin fərqli sübutlarını göstərin.

Mənbə: U4178, abzas 12-35; U4158, abzas 16-22; repo icra qeydləri.

8. Elmi sualdan yoxlanılan iddiaya

Məqsəd: geniş ideyanı konkret giriş, ölçü və qərar meyarına çevirmək. U4252-də gen ifadəsi və ML ilə xəstəlik araşdırması mövzusu təqdim olunur. Bizim konkret sualımız: “Khan benchmark-ının verilmiş training hissəsində seçilmiş model, saxlanmış test hissəsində dörd şiş sinfini hansı səhvlərlə ayırır?” Bu sual mövcud data ilə cavablandırıla bilər.

“Xərçəngi erkən aşkarlayırıq” fərqli sualdır. Bunun üçün xəstəliyin erkən mərhələləri, uyğun sağlam/nəzarət qrupu, nümunə toplama protokolu, populyasiya prevalansı və prospektiv qiymətləndirmə lazımdır. Tarixi şiş toxuması benchmark-ında yüksək accuracy həmin sübutları yaratmır. Diaqnostik tətbiq üçün xarici cohort, batch uyğunluğu, həssaslıq/spesifiklik, kalibrasiya və klinik istifadə konteksti ayrıca araşdırılmalıdır.

U4247-də miRNA və siqnal yolları barədə ədəbiyyat xülasəsi var. Xülasədən “bu miRNA səbəb olur” nəticəsi çıxarmaq olmaz. Əvvəl ilkin məqalə, eksperiment modeli, ölçmə metodu, müdaxilə və nəzarət qrupları tapılmalıdır. Pathway təsviri ilə real enrichment nəticəsi, müşahidə ilə müdaxilə sübutu ayrılır.

Hesabatın minimal forması: sual; dataset və seçim qaydası; analizdən əvvəl parametrlər; nəticə və qeyri-müəyyənlik; alternativ izah; məhdudiyyət; növbəti sınaq. Bir nəticə gözləntiyə uyğun gəlmədikdə onu gizlətmək əvəzinə məlumat keyfiyyəti, model fərziyyələri və statistik güc yoxlanılır. Yeni hipotez əvvəlki testin təsdiqi kimi təqdim edilmir.

Praktika: expression modelinin bir səhvini confusion matrix-də tapın. Yeni model seçmədən bu səhvin hansı siniflər arasında olduğunu yazın. Sonra gələcək müstəqil cohort üçün əvvəlcədən qiymətləndirmə planı qurun: hansı metrik, hansı interval, hansı qruplar və hansı istisna meyarları istifadə ediləcək?

Keçid meyarı: müşahidə, metod seçimi və gələcək hipotezi üç ayrı abzasda təqdim edin. Sizin nəticənizdən çıxarıla bilməyən bir iddianı da konkret yazın.

Mənbə: U4252, slayd 1-9; U4247, abzas 11-15; ISLP Khan mənbə kartı.

15 həftəlik praktik proqram

Hər həftə üçün təxminən 2 saat oxu, 2 saat kod və 1 saat nəticə izahı ayırın. Vaxt tövsiyədir; keçid meyarı tamamlanmadan növbəti mərhələyə keçməyin. Bu, təqdim edilmiş dərs mövzularından hazırlanmış şəxsi planıdır, rəsmi UNEC sillabusu deyil.

Həftə	Mövzu və mənbə	Təhvil verilən nəticə	Keçid meyarı
1	Məlumat və dəyişənlər, U4072	RNA metadata lüğəti	ID, kateqoriya, ölçmə fərqi
2	Database, U4084	SQLite kataloqu	744 qeyd, integrity ok
3	Data mining, U4096	Sızma riski xəritəsi	Train/test qərarları ayrılıb
4	Öyrənmə, U4114/U4117	Pipeline və CV izahı	Hər transform train fold-da
5	Genetika, U4126	VCF sahələri qeydi	REF/ALT patogenlik deyil
6	İrsiyyət, U4139	Ploidiyaya uyğun 3 nümunə	Homo/hetero/hemizigot fərqi
7	Bioinformatika, U4147	DNA analyzer icrası	FASTA-dan ölçülərə keçid
8	Tədqiqat təhsili, U4158	Öz öyrənmə xəritəniz	Mövzu ilə layihə əlaqəsi
9	Proqram təminatı, U4178	Təkrar icra hesabatı	Hash və metrik müqayisəsi
10	Bioloji bazalar, U4208	BLAST axtarış planı	Proqram/database fərqi
11	Ehtimal, U4230	Null simulyasiyası	Gözlənilən say $\neq$ sabit say
12	Hipotez, U4226/U4236	FDR və effekt izahı	P-value düzgün şərh edilir
13	Gen ifadəsi, U4252	Khan test hesabatı	20 test nümunəsi ayrıca
14	Məqalə təhlili, U4247	Bir ilkin məqalə kartı	Model, nəzarət, məhdudiyyət
15	Yekun layihə	Kod + mənbə + hesabat	Başqa şəxs təkrar işlədə bilər

Əsas oxu: praktikum. Kitab oxusu: PDF kitabxanası. Həftə 14-də ilkin məqalənin tam mətni əldə edilməzsə, kartda abstract-only statusu açıq saxlanmalıdır.

Qiymətləndirmə

- 30% düzgün data və mənbə qeydi.
- 30% işlək analiz və yoxlamalar.
- 25% nəticənin məhdudiyyətlərlə izahı.
- 15% təkrar icra və aydın sənədləşmə.

Yüksək model balı özü qiymətləndirmə meyarı deyil. Səhvi düzgün aşkar edib izah etmək yaxşı tədris nəticəsidir.

24 tapşırıq və cavab açarı

Əvvəl praktikumu oxuyun. Hər bölmənin üç sualını cavaba baxmadan həll edin. Kodlu tapşırıqlarda nəticə və izahı birlikdə saxlayın.

1. Məlumat

1. `sample_id=17`, `condition=treated`, `count=0` dəyişənlərini təsnif edin.
2. Metadata-nın sırası tərsinə çevrilsə, cədvəllər necə birləşdirilməlidir?
3. Eyni SHA-256 elmi doğruluğu sübut edirmi?

Cavablar: 1) ID, kateqoriya, tam sayım. 2) `sample_id` üzrə; sıra üzrə deyil. 3) Xeyr, yalnız bayt uyğunluğunu yoxlamağa kömək edir. Mənbə və metod ayrıca qiymətləndirilir.

2. SQL

4. 124 gen və 6 nümunənin tam ölçmə cədvəlində neçə qeyd olar?
5. Eyni (`sample_id`, `gene_id`) cütünü yenidən yazmaq hansı qaydanı pozur?
6. `count=-1` və `count=1.5` qəbul edilməlidirmi?

Cavablar: 4) 744. 5) Birləşmiş əsas açarı. 6) Raw count cədvəlində hər ikisi rədd edilməlidir; TPM üçün başqa sxem qurulur.

3. Maşın öyrənməsi

7. Feature selection bütün data-da CV-dən əvvəl edilsə nə baş verir?
8. Recall-lar 1, 5/6, 1, 1 olduqda balanced accuracy-ni hesablayın.
9. Test nəticəsinə baxıb hiperparametrləri dəyişdikdə nə itirilir?

Cavablar: 7) Validation məlumatı seçimə sızır; score optimist ola bilər. 8) $23/24 = 0.95833$. 9) Testin müstəqil son qiymətləndirmə rolu; yeni untouched data lazımdır.

4. Genetika

10. VCF 0/1 ilə 0|1 arasındakı fərq nədir?
11. REF alleli həmişə sağlam alleldirmi?
12. Poligenlik və pleiotropiyanı ayırın.

Cavablar: 10) İkincidə faza məlumatı göstərilir. 11) Xeyr, REF referens ardıcılığın allelidir. 12) Çox gen → bir xüsusiyyət; bir gen → bir neçə xüsusiyyət.

5. Sequence axtarışı

13. Nukleotid sorğunu tərcümə edib protein bazasında hansı proqram axtarır?

14. 100% identity, 12 nt alignment gen funksiyasını sübut edirmi?

15. BLAST score 200 olduqda alignment 200 bp olmalıdır mı?

Cavablar: 13) BLASTX. 14) Xeyr; coverage, təsadüfi uyğunluq və digər sübutlar lazımdır. 15) Xeyr; score və uzunluq müxtəlif ölçülərdir.

6. Statistika

16. 1000 kalibrə edilmiş həqiqi null testdə $\alpha=0.05$ üçün gözlənilən yanlış müsbət sayı?

17. $p=0.03$ H_0 -ın doğru olma ehtimalının 3% olduğunu bildirirmi?

18. Bu simulyasiyada BH-dən sonra sıfır nəticə qalması ümumi zəmanətdirmi?

Cavablar: 16) 50; hər realizasiyada eyni say deyil. 17) Xeyr; ehtimal H_0 /model şərti altında test statistikasına aiddir. 18) Xeyr; FDR uyğun şərtlərdə gözlənilən payı idarə edir.

7. Təkrar icra

19. NumPy $a*b$ və $a@b$ nə ilə fərqlənir?

20. Seed eyni olsa da paket versiyası dəyişsə nəticə dəyişə bilər mi?

21. İki run qovluğunun adı fərqlidir, xülasələri eynidir. Bu uyğunsuzluqdur mu?

Cavablar: 19) Elementlər üzrə və matris vurması. 20) Bəli; seed bütün mühit fərqlərini idarə etmir. 21) Xeyr; yeni vaxt/unikal run kimliyi gözlənilir. Elmi nəticəni ayrıca müqayisə edin.

8. Elmi iddia

22. 20 şiş toxumasında 95% accuracy erkən xərçəng skriningini təsdiqləyirmi?

23. V17 ən yaxşı xüsusiyyətdirsə onu gen biomarkeri adlandırmaq olarmı?

24. U4247-dəki miRNA xülasəsini ilkin məqalə reproduksiyası saymaq olarmı?

Cavablar: 22) Xeyr; uyğun populyasiya, nəzarət, mərhələ və xarici validasiya yoxdur. 23) Əvvəl probe-gen xəritəsi və müstəqil sübut lazımdır. 24) Xeyr; ilkin data və metodla ayrıca icra tələb olunur.

Mənbələrdə dəqiqləşdirmələr

Bu qeydlər müəlliflər haqqında qiymətləndirmə deyil; konkret ifadələrin laboratoriyada necə düzəldildiyini göstərir. Sitatlar uzun mətn köçürməsi deyil, məzmunun qısa təsviridir. Mənbə kimlikləri kataloqda tapılır.

Mənbə yeri	Problem	Dərsdə istifadə olunan dəqiq izah
U4208, slayd 12	BLASTN/BLASTX database kimi təqdim olunur	Bunlar axtarış proqramlarıdır; database ayrıca seçilir
U4208, slayd 14	Score həddi bp uzunluğu kimi şərh olunur	Alignment score və alignment length ayrı ölçülərdir
U4208, slayd 9	PubMed girişindən bütün tam mətnlərə sərbəst giriş nəticəsi çıxarıla bilər	Bibliografik qeyd ilə məqalənin tam mətninə giriş ayrı şeylərdir
U4226, abzas 41	H0 əvvəl sübut edilmiş fikir və ya rədd olunmayanda qəbul olunan həqiqət kimi verilir	H0 sınaqdan keçirilən hipotezdir; rədd etməmək sübut deyil
U4226, abzas 46	İki fərqli orta təkbəşinə rədd qərarı üçün kifayət sayılır	Variasiya, nümunə sayı, dizayn və uyğun model lazımdır
U4236, abzas 12	$p < 0.05$ sübut və fərdi nəticədə maksimum 5% səhv kimi şərh edilir	P-value H0/model şərti altında statistikaya aid ehtimaldır
U4126, abzas 51	Hipomorfizm genotip-mühit uyğunsuzluğu kimi izah edilir	Hipomorf allel gen funksiyasını azaldan alleldir
U4126, abzas 52	Mürəkkəb xüsusiyyətlər ümumi şəkildə pleiotropiya ilə eyniləşdirilir	Poligenlik və pleiotropiya fərqli istiqamətli əlaqələrdir
U4139, abzas 22	Spermada mitoxondrinin praktik yoxluğu iddiası	Spermada mitoxondri mövcuddur; maternal irsiyyət ayrıca mexanizmlə izah olunur
U4147, abzas 22	İstənilən yol/gen pozuntusu mütləq xəstəlik kimi şərh edilir	Nəticə variantdan, funksional ehtiyatdan, toxumadan və digər amillərdən asılıdır
U4252, slayd 1-9	Ümumi erkən diaqnostika ideyası ilə işlək model arasında sübut boşluğu	Khan analizi şiş siniflərini ayıran tədris benchmark-ıdır; skrininq validasiyası deyil

Yoxlama üçün mənbələr

- NCBI BLAST Help: proqramlar və nəticə anlayışları.
- NHGRI: Allele: allel anlayışı.
- Rapid generation of hypomorphic mutations: gen fəaliyyətinin azaldılması və hipomorf allellər; giriş hissəsi.
- Molecular Basis for Maternal Inheritance of Human Mitochondrial DNA: sperm mitoxondriləri və mtDNA irsiyyəti; abstract və giriş hissəsi.
- Think Stats PDF, fəsil 9: hipotez yoxlaması, effekt və qeyri-müəyyənlik.
- Khan məlumat kartı: hansı nümunələrin qiymətləndirildiyi və məhdudiyyətlər.

Səhv qeydi bütün mənbənin istifadəsiz olduğu mənasına gəlmir. Mənbədəki faydalı mövzular saxlanılır, yeni iddialar isə ayrıca sübutla əsaslandırılır.

Mənbə və PDF kitabxanası

Konspektdə U ilə başlayan kimliklər orijinal UNEC faylının son dörd rəqəmidir. Məsələn U4252: UNEC__1789524252.pptx. Abzaslar yerli mətn çıxarışının, PDF səhifələri fiziki səhifələrin nömrələridir. Seçilmiş hissələr oxunub; bütün kitablar və şəkil ağırlıqlı slaydlar tam yoxlanmış sayılır.

Think Stats, second edition

Allen B. Downey | 264 səhifə.

[resources/books/pdf/think-stats-2e.pdf](#)

CC BY-NC-SA 4.0

Computational Biology: Genomes, Networks, Evolution

Manolis Kellis and course contributors | 547 səhifə.

[resources/books/pdf/mit-computational-biology.pdf](#)

MIT OCW CC BY-NC-SA 4.0; preserve embedded third-party notices

Statistika

F. N. Əliyev, C. İ. Mikayılov, Y. N. Əliyev | 246 səhifə.

[resources/unec/pdf/statistika-az-2015.pdf](#)

User-supplied study copy; no open redistribution license established; original rights retained

Data Science and Machine Learning: Mathematical and Statistical Methods

Dirk P. Kroese, Zdravko I. Botev, Thomas Taimre, Radislav Vaisman | 533 səhifə.

[resources/unec/pdf/data-science-machine-learning-2022.pdf](#)

User-supplied study copy; no open redistribution license established; original rights retained

Orijinal mənbələr dəyişdirilməyib. İstifadəçinin təqdim etdiyi iki kitab üçün açıq yayım lisenziyası müəyyən edilməyib. Müəllif hüquqları saxlanılır. Yeni konspektlə orijinal kitabların müəllifliyi bir-birindən ayrılır.

Yekun qeyd

Təlim nəticəsi yalnız yüksək model balı deyil: mənbəni tapmaq, düzgün sual qurmaq, analizi təkrarlamaq və nəticənin sərhədini izah etməkdir.